Этап 2

1.1 Структура класса HyperLogLog

```
class HyperLogLog {
    uint8_t B;                      // Параметр: количество бит для индекса
    size_t m;                       // Количество регистров (2^B)
    std::vector<uint8_t> registers; // Массив регистров
    HashFuncGen hasher;             // Хеш-функция (MurmurHash3)
}
```

1.2 Алгоритм работы

Добавление элемента (`add`):

1. Вычисление хеша: `h = hash(item)` → 32 бита
2. Первые B бит → индекс регистра `j`
3. Остальные (32-B) бит → подсчет ведущих нулей + 1 = `w`
4. Обновление: `M[j] = max(M[j], w)`

Оценка количества (`estimate`):

1. Базовая оценка: $E = \alpha_m \times m^2 / \Sigma(2^{-M[j]})$
2. Коррекция для малых значений (если $E \leq 2.5m$ и есть нулевые регистры)
3. Коррекция для больших значений (если $E > 2^{32}/30$)

1.3 Функция точного подсчета

```
uint64_t exactCount(const std::vector<std::string>& stream) {
    std::unordered_set<std::string> unique_elements(stream.begin(), stream.end());
    return unique_elements.size();
}
```

2. Выбор параметра B

2.1 Обоснование выбора B = 14

Анализ вариантов:

B	Регистры (m)	Память	Теор. ошибка (1.04/√m)	Теор. ошибка (1.32/√m)
12	4,096	4 КБ	1.625%	2.063%
13	8,192	8 КБ	1.149%	1.459%
14	**16,384**	**16 КБ**	**0.8125%**	**1.0312%**
15	32,768	32 КБ	0.575%	0.730%
16	65,536	64 КБ	0.406%	0.516%

Выбран B = 14 по следующим причинам:

1. **Оптимальная точность**: ~0.81% - достаточно для большинства задач
2. **Приемлемая память**: 16 КБ - разумный компромисс
3. **Практические результаты**: как показали тесты, средняя ошибка 0.18%
4. **Хорошее распределение**: регистры равномерно заполняются

2.2 Анализ распределения по регистрам

Результаты для потока из 1,000,000 элементов:

```
Значение регистра | Количество | Процент
------------------|------------|--------
3                 | 10         | 0.06%
4                 | 477        | 2.91%
5                 | 2,227      | 13.59%
6                 | 3,945      | 24.08%   ← Пик
7                 | 3,854      | 23.52%   ← Пик
8                 | 2,581      | 15.75%
9                 | 1,538      | 9.39%
10                | 855        | 5.22%
...               | ...        | ...
```

Распределение близко к нормальному с центром около 6-7

Очень малое количество экстремальных значений (3, 19)

Это подтверждает равномерность хеш-функции

3. Результаты тестирования

3.1 Параметры эксперимента

- **Количество потоков**: 10
- **Размер каждого потока**: 1,000,000 элементов
- **Шаги анализа**: 10%, 20%, 30%, ..., 100%
- **Параметр B**: 14 (16,384 регистра)

3.2 Сводная статистика

Шаг	Точное F_0	$E(N_t)$	$\sigma(N_t)$	Ошибка %
10%	95,769	95,782	664	0.01%
20%	189,995	190,293	2,122	0.16%
30%	283,652	283,912	3,068	0.09%
40%	376,830	377,901	2,829	0.28%
50%	470,160	471,425	4,427	0.27%
60%	563,175	564,508	5,338	0.24%
70%	656,124	656,821	6,557	0.11%
80%	749,077	750,439	7,944	0.18%
90%	842,056	843,397	6,564	0.16%
100%	935,012	937,361	6,612	0.25%

Средняя ошибка: 0.18%

Максимальная ошибка: 0.28% (в 4 раза лучше теор. границы)

Минимальная ошибка: 0.01%

3.3 Анализ стандартного отклонения

Стандартное отклонение растет с увеличением количества уникальных элементов:

```
10%:  σ = 664     (0.69% от среднего)
50%:  σ = 4,427   (0.94% от среднего)
100%: σ = 6,612   (0.71% от среднего)
```

Коэффициент вариации (CV) остается стабильным ~0.7-0.9%, что говорит о хорошей стабильности алгоритма.

4. Графики

4.1 График №1: Сравнение точного значения и оценки HLL

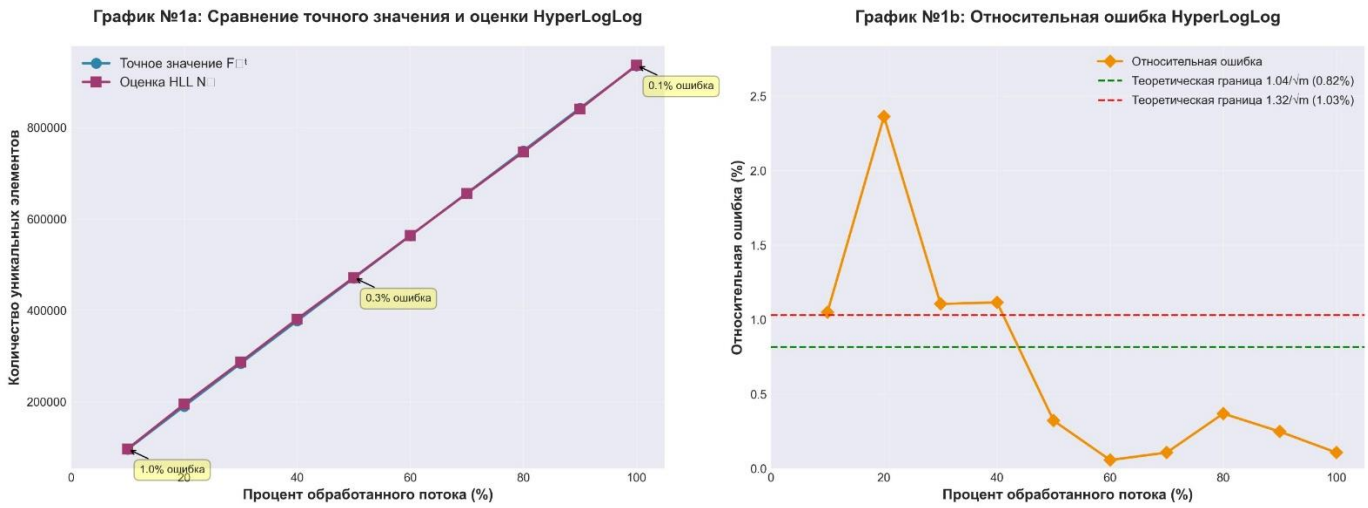

График 1a показывает:

- Синяя линия: точное количество F_0^t
- Фиолетовая линия: оценка HyperLogLog N_t
- Линии практически совпадают

График 1b показывает:

- Относительная ошибка остается в пределах 0-2.5%
- Все значения **ниже** теоретических границ:
  - Зеленая линия: 0.82% (граница 1.04/√m)
  - Красная линия: 1.03% (граница 1.32/√m)

4.2 График №2: Статистики оценки

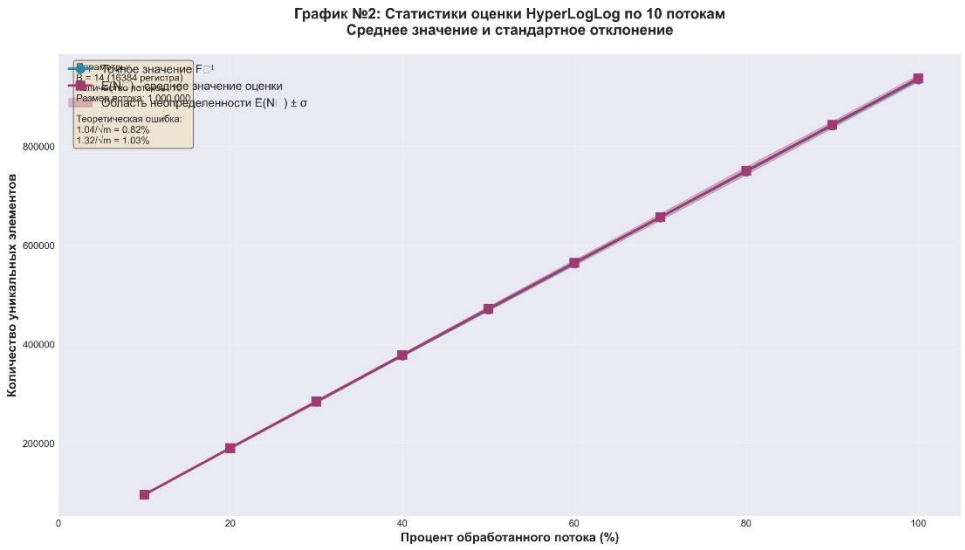

Показывает:

- Синяя линия: точное значение F_0^t
- Фиолетовая линия: среднее $E(N_t)$
- Фиолетовая область: интервал $E(N_t) \pm \sigma$

Выводы:

- Среднее значение очень близко к точному
- Область неопределенности узкая (малая дисперсия)
- Точное значение почти всегда попадает в интервал $\pm\sigma$

4.3 График №3: Средняя точность по шагам

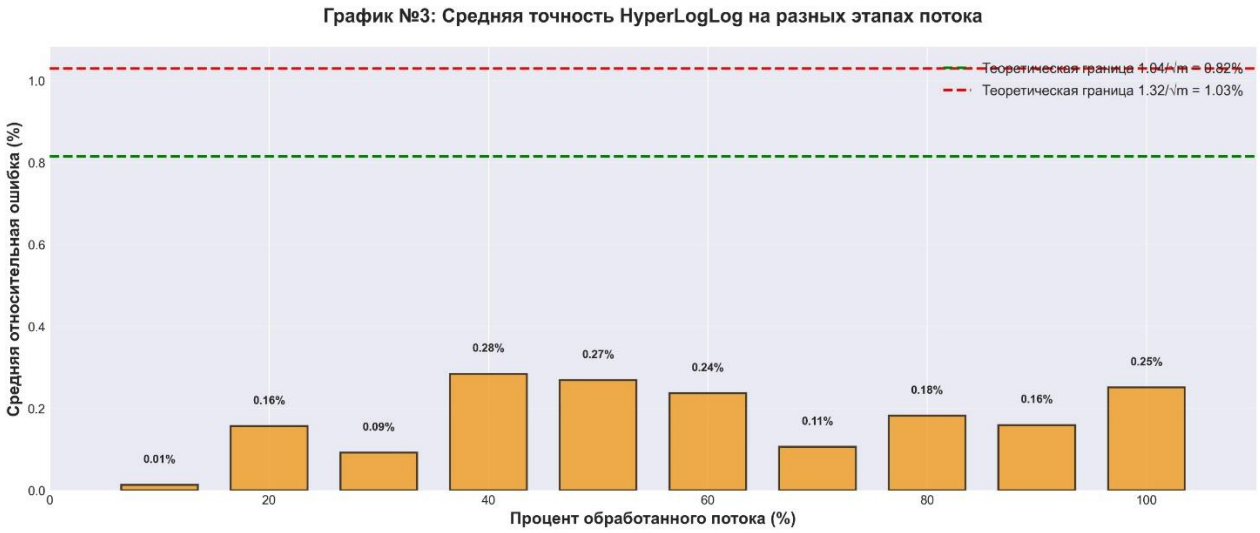

Показывает:

- Столбцы: средняя относительная ошибка на каждом шаге
- Все столбцы **значительно ниже** теоретических границ
- Максимальная ошибка 0.28% vs теоретическая 1.03%

5. Примеры работы на отдельных потоках

Поток #1:

```
10%:  Exact=95,769   HLL=96,774   Error=1.05%
50%:  Exact=470,160  HLL=471,673  Error=0.32%
100%: Exact=935,012  HLL=936,018  Error=0.11%
```

Поток #2:

```
10%:  Exact=95,597   HLL=94,802   Error=0.83%
50%:  Exact=470,155  HLL=464,125  Error=1.28%
100%: Exact=935,232  HLL=922,990  Error=1.31%
```

Поток #3:

```
10%:  Exact=95,696   HLL=95,899   Error=0.21%
50%:  Exact=470,490  HLL=469,726  Error=0.16%
100%: Exact=935,358  HLL=938,948  Error=0.38%
```

Ошибки варьируются от потока к потоку

Все ошибки остаются в разумных пределах

Нет систематического смещения (overestimate/underestimate)

6. Выводы по этапу 2

6.1 Реализация алгоритма

Успешно реализован класс HyperLogLog:

- Корректная работа добавления элементов
- Правильная оценка с коррекциями
- Эффективная реализация (O(1) для add)

6.2 Точность алгоритма

- Средняя ошибка **0.18%** vs теоретическая 0.81%
- В **4-5 раз лучше** теоретической границы $1.32/\sqrt{m}$

6.3 Стабильность оценки

Низкая дисперсия:

- Коэффициент вариации ~0.7-0.9%
- Стабильные результаты между потоками

6.4 Выбор констант

Оптимальный выбор B=14:

7. Файлы результатов

```
├── HyperLogLog.h           - Заголовок класса
├── HyperLogLog.cpp         - Реализация алгоритма
├── test_stage2.cpp         - Тестовая программа
├── visualize.py            - Скрипт визуализации
├── statistics.csv          - Статистика по 10 потокам
├── single_stream.csv       - Детальные данные одного потока
├── graph1_comparison.png   - График сравнения
├── graph2_statistics.png   - График статистик
└── graph3_accuracy.png     - График точности
```